第 43 卷第 1 期 波 谱 学 杂 志 Vol. 43 No. 1
2026 年 3 月 Chinese Journal of Magnetic Resonance Mar. 2026

Chinese J Magn Reson, 2026, 43(1): 71-86 doi:10.11938/cjmr20253158 cstr:32225.14.cjmr20253158

轻量化 AD-Net 模型用于颅内肿瘤 MRI 图像的分类研究

向朝，随力*，张昊天，段梦雨，刘卓睿

上海理工大学健康科学与工程学院，上海 200093

摘 要：颅内肿瘤是一种严重的神经系统疾病，早期检测对提高患者生存率具有重要意义．然而，现有深度学习模型在颅内肿瘤图像分类任务中仍面临特征提取不足、模型复杂度较高以及类别不均衡等问题．为此，本研究提出了一种轻量化深度学习网络即自适应动态网络（AD-Net）．该网络创新性地引入动态卷积机制，自适应调整滤波器响应，从而增强了对颅内肿瘤复杂、不均特征的表征能力；结合通道注意力机制，有效聚焦关键通道信息，进一步提升了分类的准确性与模型的可解释性．此外，本研究提出了结合二分类与三分类的训练策略，显著缩短了模型训练时间，降低了对计算资源的需求，使其更适用于资源受限的医疗环境．在实验中，AD-Net 在准确率、精确率、召回率、F1 分数以及 Kappa 系数等关键评价指标上均优于现有主流深度学习模型，验证了其在颅内肿瘤分类任务中的有效性与实际应用价值．

关键词：颅内肿瘤分类；卷积神经网络；动态卷积；通道注意力机制；轻量化模型

中图分类号：O482.53 **文献标识码：**A

A Lightweight AD-Net Model for the Classification of Intracranial Tumors in MRI Images

XIANG Zhao，SUI Li，ZHANG Haotian，DUAN Mengyu，LIU Zhuorui*

School of Health Science and Engineering, University of Shanghai for Science and Technology, Shanghai 200093, China

Abstract: Intracranial tumors represent a serious neurological disorder, and early detection is critical for improving patient survival rates. However, current deep learning models for intracranial tumor image classification often suffer from insufficient feature extraction, high model complexity, and class imbalance. To address these challenges, this study proposes a lightweight deep learning architecture, the adaptive dynamic network (AD-Net). The network innovatively incorporates a dynamic convolution mechanism that adaptively adjusts filter responses, thereby enhancing the representation of complex and imbalanced tumor features. Additionally, the integration of a channel attention mechanism enables the model to focus on critical channel information, further improving classification accuracy and interpretability. This study also introduces a combined binary and ternary classification training strategy, which significantly reduces training time and computational resource requirements, making the model more suitable for resource-constrained medical settings. Experimental results demonstrate that AD-Net outperforms existing mainstream deep learning models in accuracy, precision, recall, F1 score, and Cohen's Kappa coefficient, confirming its effectiveness and practical value for intracranial tumor classification.

Keywords: intracranial tumor classification, convolutional neural network (CNN), dynamic convolution, channel attention mechanism, lightweight model

收稿日期：2025-04-08; **在线发表日期：**2025-06-12

基金项目：国家自然科学基金资助项目(11179015, 51173108)；上海理工大学科技发展项目(2019KJFZ239, 2020KJFZ232).

通信作者(Corresponding author): * Tel:13524686264, E-mail: lsui@usst.edu.cn.

引 言

颅内肿瘤作为全球健康领域中的重大难题，具有较高的发病率和死亡率[1]. 据世界卫生组织（World Health Organization，WHO）统计，脑及中枢神经系统肿瘤约占全球癌症总数的 2%[2]. 美国癌症协会的最新数据显示，仅 2023 年，美国新增恶性脑与脊髓肿瘤（含颅内）病例约 24 810 例，死亡人数超过 18 000[3]. 颅内肿瘤不仅严重威胁患者的生命健康，亦对社会带来巨大经济负担，包括高昂的治疗费用、劳动力损失以及长期护理等多重压力.

在颅内肿瘤的诊断与治疗过程中，磁共振成像（Magnetic Resonance Imaging，MRI）因其无创性和优异的软组织分辨能力，被广泛认为是肿瘤检测与分类的金标准[4]. 对颅内肿瘤进行精准分类（如胶质瘤、脑膜瘤、垂体瘤等）对于制定个体化治疗方案和预后评估至关重要. 自动化分类技术能够有效辅助放射科医生，显著缩短诊断时间，提高诊断的准确性与一致性，从而改善临床治疗效果[5].

然而，当前临床上颅内肿瘤的诊断主要依赖于放射科医生对 MRI 图像的人工识别，诊断结果受医生主观经验和视觉敏感性影响较大[6]. 此类主观性较强的评判方式容易导致医生间一致性差的问题，且在处理边界模糊或形态复杂的肿瘤时存在误诊和漏诊风险. 此外，影像诊断过程本身较为耗时，加重了医生的工作负担，难以应对医疗影像数据日益增长的趋势[6]. 因此，构建高效、客观的辅助诊断系统以提升颅内肿瘤分类的准确性和效率，已成为亟待解决的现实需求[7].

为应对上述挑战，研究者们早期开发了多种基于传统机器学习算法的 MRI 颅内肿瘤分类方法. 传统的 MRI 颅内肿瘤分类方法通常依赖手工特征提取与经典机器学习算法，但这类方法存在诸多自身的技术局限性. 例如，手工特征难以全面捕捉肿瘤复杂的生物学特征；不同 MRI 影像设备与成像协议的差异导致模型泛化性能较差；计算效率不足也使得诊断流程耗时较长，难以满足实际临床需求[8].

目前，已有多种机器学习方法被广泛应用于 MRI 颅内肿瘤分类任务中，包括支持向量机（Support Vector Machine，SVM）、随机森林（Random Forest，RF）以及 K 近邻（K-Nearest Neighbors，KNN）等经典算法[9]. 其中，SVM 方法在小规模数据集上表现出良好性能，但难以处理更加复杂的特征模式；随机森林方法虽然准确性较高，但参数调优复杂；而 KNN 方法则由于简单直接的实现机制，在处理大规模数据集时面临高昂的计算成本. 近年来，随着深度学习技术的迅猛发展，卷积神经网络（Convolutional Neural Network，CNN）凭借其自动的分层特征学习能力，已成为 MRI 颅内肿瘤分类领域的主流方法，尤其在大规模医学影像数据处理方面展现出显著优势[10].

越来越多的研究致力于利用卷积神经网络实现多类别颅内肿瘤的高效识别，这主要归功于其在高级特征表达及医学图像分析等视觉任务中的突出表现. 例如，Paul 等人[2]比较了全连接网络与 CNN 在颅内肿瘤分类中的适用性；Asfhar 等人[7]提出了用于颅内肿瘤分类的胶囊网络（CapsNet），通过动态路由机制提升空间结构建模能力，但其网络结构复杂、训练过程不稳定. 随后，他们改进的 CapsNet 不仅处理脑部 MRI 图像，还引入了肿瘤粗略边界作为输入，以提升性能. Swati 等人[10]采用 VGG19 结合块状微调（Block-wise Fine-Tuning，BFT）方法对颅内肿瘤进行分类，但该方法对预训练权重依赖程度较高，对硬件资源要求较大. Ghassemi 等人[11]训练了一个作为生成对抗网络（Generative Adversarial Network，GAN）判别器的深度神经网络，并将其应用于颅内肿瘤分类任务. 为了进一步优化 CapsNet 的结构，Afshar 等人[12]提出了增强胶囊网络（BoostCaps）；Bodapati 等人[13]将 Xception 和 InceptionResNetV2 提取的特征通过平均池化方式融合，构建了双通道深度神经网络结构. 与此同时，Kalkhof 等人[14]提出了基于神经元元胞自动机的轻量级神经网络 Med-NCA，实现了对医学图像的稳健分割，为后续分类任务提供了更加精确的区域特征. 最新研究[15]基于边界柯里萤火虫算法（Border Collie Firefly Algorithm，BCFA）与 GAN 相结合的方法，用于肿

瘤分级分类，但生成式方法对训练样本质量较为敏感，模型泛化能力仍需进一步提升.

尽管基于卷积神经网络（CNN）的方法在颅内肿瘤分类性能方面实现了一定提升，但传统 CNN 在捕捉同一类别肿瘤内部的微小尺度差异及类别之间的细粒度特征时仍存在局限性．此外，传统 CNN 在建模全局依赖关系方面能力有限，这在一定程度上增加了其实际临床应用的难度．近年来，注意力机制被引入到 CNN 架构中，作为提升模型性能的关键组件．注意力机制能够引导模型聚焦于关键信息区域，有效抑制无用特征，从而在多个计算机视觉任务中取得了显著成效[16-19]. 然而，针对其在颅内肿瘤分类中的应用，相关研究仍相对较少[20]．相关工作有 Bodapati 等人[21]提出引入压缩和激励模块的 MSENet 模型，Dutta 等人[22]将通道混洗双注意力块与主干网络结合等以提升肿瘤分类性能．受上述研究启发，本文提出了一种基于改进 ResNet50 结构的深度学习方法，融合动态卷积与通道注意力机制，命名为 AD-Net，以此来提升颅内肿瘤分类的精度与泛化能力．本文的主要贡献包括：

（1）将二分类与三分类结合的训练策略，大大缩短了模型的训练时间并减少了对计算资源的需求．这种方法不仅提高了训练效率，还通过轻量化网络结构，使模型更适合在资源受限的环境中部署.

（2）引入动态卷积，该技术能够根据图像的不同部分自动调整滤波器响应，从而针对颅内肿瘤图像中多变的形状和尺寸提供更精确的特征提取．这一策略显著提高了模型对颅内肿瘤图像中不同病变区域的适应性和识别精度.

（3）通过融合通道注意力机制，AD-Net 进一步增强了对图像中关键特征的关注能力．该机制通过聚焦于最具信息量的特征通道，优化了网络的特征提取过程，从而提高了分类的准确性和模型的解释性.

1　研究方法

1.1　实验流程

本文提出二分类结合三分类的流程，如图 1 所示，旨在提高分类精度并显著降低计算复杂性．整个流程分为两个阶段进行，具体而言，以确保既能够快速地识别无肿瘤的图像，又可以精确地区分肿瘤类型．首先，输入的 MRI 图像被送入预处理阶段，这里进行图归一化和尺寸调整，以统一输入图像的标准，提升后续模型识别的效率和准确性．接下来进入第一阶段，该阶段使用数据集一（Dataset-1）对图像进行二分类，即判断图像中是否存在肿瘤，目的是快速筛选出正常脑组织图像和存在肿瘤的图像．经过 AD-Net 特征提取，并利用训练出的网络权重，可迅速区分正常与异常图像，从而避免了后续对所有图像进行三分类的计算负担，显著降低了计算复杂性，提升了整体处理效率．当确认图像中存在肿瘤后，再将筛选出来的肿瘤图像送入流程的第二阶段，此阶段使用数据集二（Dataset-2）进行更精细的三分类任务，以区分不同类型的肿瘤（胶质瘤、脑膜瘤和垂体瘤）．第二阶段利用第一阶段训练网络的权重作为初始化，以迁移学习的方式进一步进行训练，从而提高了分类模型的泛化性能和训练速度．由于二分类任务有效减少了大量不必要的计算，使得这一阶段的三分类任务更具针对性，模型在较少的数据中就能快速达到高精度．两阶段的分类策略在保证高分类精度的同时，大幅减少了计算负荷，并且有效利用了迁移学习的优势，使得整个颅内肿瘤分类流程更加高效、更具实用价值，尤其适用于临床诊断需求高效率、高精确度的医疗场景.

1.2　网络整体结构

基于 ResNet50 改进后的深度学习网络（AD-Net）如图 2 所示，主要针对三种颅内肿瘤类型以及正常脑部图像进行分类．整个网络的设计可以分为特征提取（Feature Extraction）、注意力增强（Attention Enhancement）、特征融合（Feature Fusion）以及分类输出（Classification Output）四个主要部分.

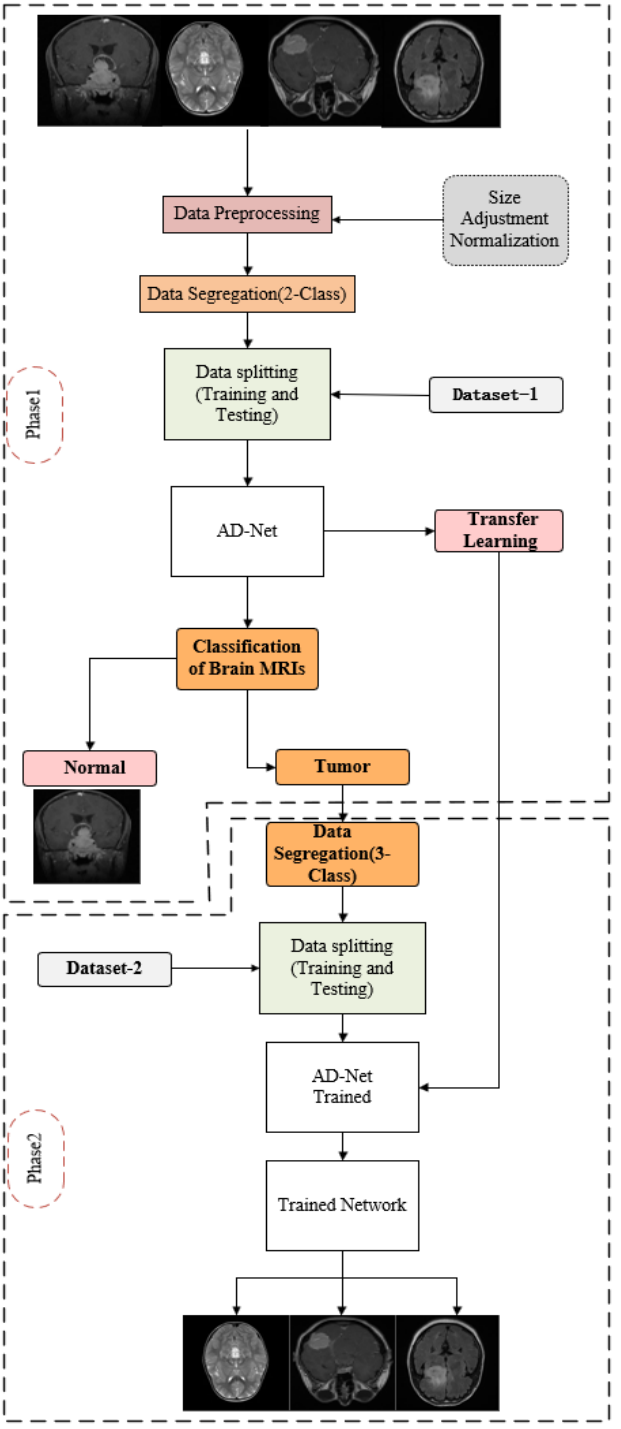


图 1 改进的实验流程

Fig. 1 Improved experimental procedure

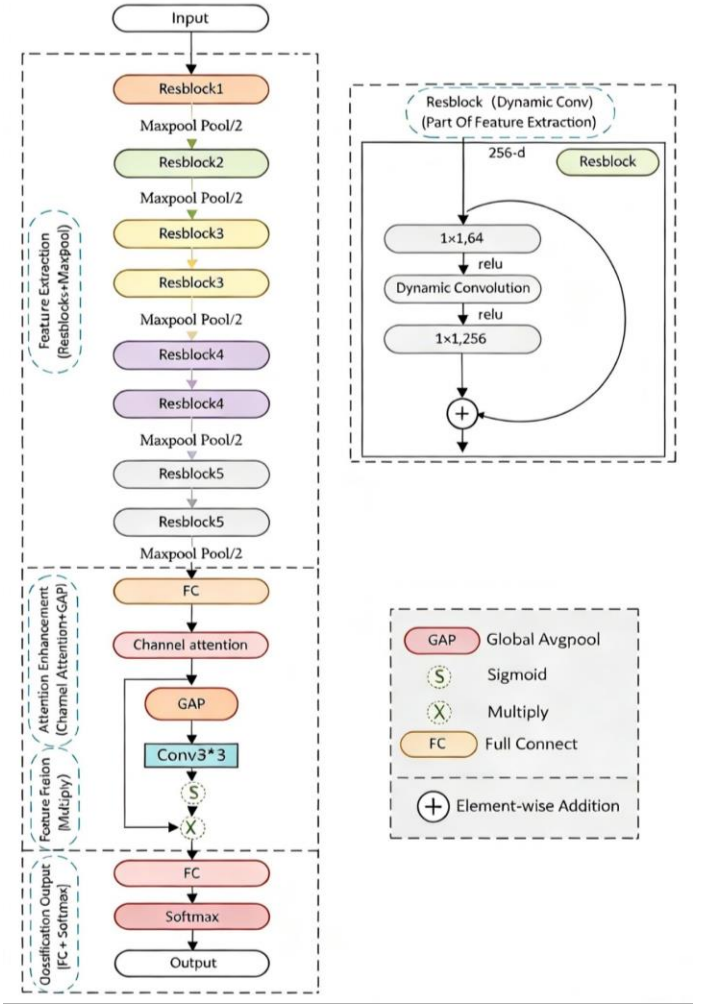


图 2　AD-Net 的网络结构

Fig. 2　Network structure of AD-Net

1.3　ResNet50 基础网络

本文提出的网络编码器采用 ResNet50[23]作为骨干网络提取颅内肿瘤图像特征，如图 3 所示，首先，输入图像数据经过初始的残差模块（Resblock1）提取初级特征；随后，通过最大池化（Maxpool Pool/2）减小特征图的空间尺寸并突出重要特征；紧接着，依次通过多个残差模块组（Resblock2 至 Resblock5），每经过一个模块组便进行一次最大池化操作，使网络逐渐提取更加高级和抽象的特征信息；最后特征图经由全连接（FC）层，并通过 Softmax 激活函数完成分类任务，得到预测类别[24,25].

具体到残差模块的结构，每个 Resblock 由主路径和捷径路径（Shortcut）两部分构成．主路径上首先经过一个 1×1 的卷积（Conv）降低特征通道数，然后通过 relu 激活，接着再进行 3×3 卷积操作捕捉空间特征，并再次激活，最后经过 1×1 卷积将特征通道恢复至原维度．捷径路径则绕过主路径直接将输入特征与主路径的输出特征相加[26]. 这种结构设计使得网络只需要学习输入与输出间的残差差异，而不是全部映射，从而有效避免了深层网络的梯度消失与爆炸问题，极大提高了网络的训练性能和效率，使得 ResNet 在图像分类、检测等任务中表现突出[27].

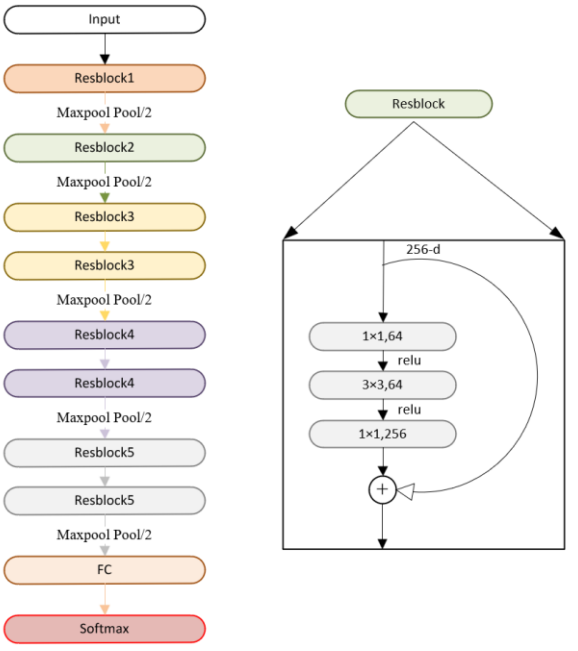


图 3 ResNet50 基础网络图[23]

Fig. 3 The basic architecture of ResNet50[23]

1.4 动态卷积模块

本文引入了动态卷积[28]（Dynamic Convolution）模块，如图 4 所示，这是一种创新的卷积操作，其目标在于提升模型对颅内肿瘤 MRI 图像复杂特征的自适应捕捉能力. 具体而言，动态卷积利用多个不同的卷积核，这些卷积核拥有相同的尺寸以及输入输出通道数，但它们的参数是不相同的. 这些不同的卷积核通过特定的注意力权重动态地聚合，从而构建出更加灵活和高效的特征提取过程.

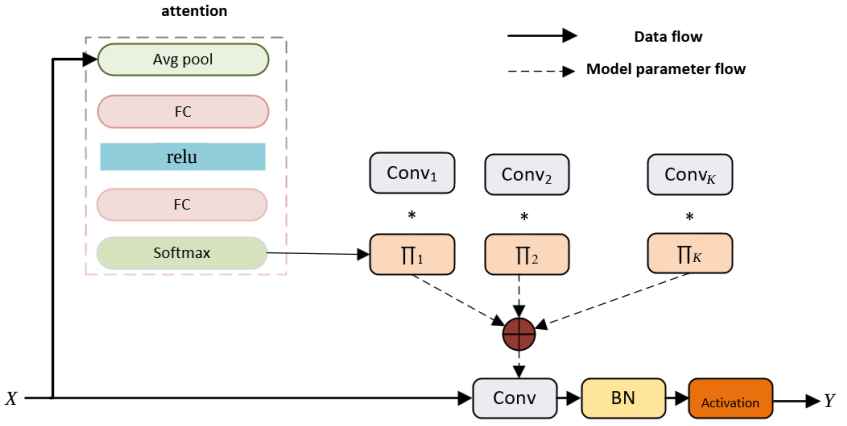


图 4 动态卷积模块[28]

Fig. 4 Dynamic convolution module[28]

该模块通过通道注意力机制自适应调整不同卷积核的权重，以提升特征提取能力. 首先，利用全局平均池化捕获全局特征，并通过两层全连接（FC）+ relu 计算注意力分布，经过 Softmax 归一化后生成 K 组动态权重. 随后，依据这些权重对 K 组预设卷积核进行加权求和，得到最终动态卷积核，并用于卷积操

作．最终，通过归一化（Batch Normalization, BN）和非线性激活函数优化输出特征．该方法使卷积操作具备更强的自适应性，有助于提升模型的特征表征能力和泛化能力．该模块具体计算过程如下：

首先对于输入特征 X，使用注意力模块增强模型对重要特征的感知能力，使用通道注意力模块提取通道特征：

$$X_{\text{pool}} = \text{avgpool}(X) \tag{1}$$

$$X_{\text{hidden}} = \text{relu}(\text{FC}(X_{\text{pool}})) \tag{2}$$

$$A = \text{Softmax}(\text{FC}(X_{\text{hidden}}/T)) \tag{3}$$

其中 X_{pool} 表示通道平均特征，提取每通道全局信息；X_{hidden} 为非线性特征表示，提取压缩后的通道嵌入；A 表示注意力分布权重，决定动态卷积组合方式；T 表示 Softmax 中的温度系数，控制注意力的选择性；avgpool 表示全局平均池化，relu 表示激活函数，FC 表示全连接层．接下来通过多组动态卷积计算模型的输出 Y_{out}，预设 K 组卷积，首先进行注意力加权求和：

$$W_{\text{dyn}} = \sum_{k=1}^{K} \text{Conv}_k(A_k) \tag{4}$$

$$Y = \text{Conv}(X, W_{\text{dyn}}) \tag{5}$$

$$Y_{\text{out}} = \text{Activation}(\text{BN}(Y)) \tag{6}$$

其中 Conv 表示卷积操作，Conv_k 表示第 k 个预设卷积核，W_{dyn} 表示动态组合的卷积核，A_k 表示第 k 个卷积核的注意力权重，Activation 表示激活层．

1.5　通道注意力机制

图 5 中展示的是一种专门设计的通道注意力模块，其目的是增强网络对颅内肿瘤 MRI 图像特征的长距离依赖关系建模能力．在本文的颅内肿瘤分类任务中，不同通道的特征表达着肿瘤组织与正常组织的重要区别，捕捉这些通道之间的全局关系能显著提升分类的准确性．

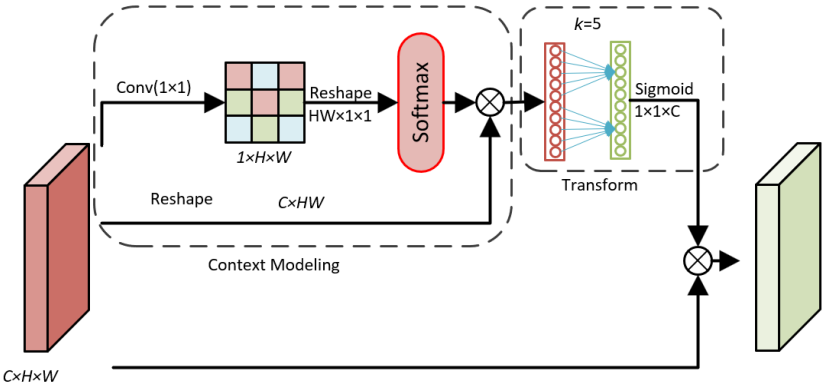


图 5　通道注意力模块

Fig. 5　Channel attention module

具体而言，通道注意力模块首先将输入的特征图 $X \in R^{C\times H\times W}$（$C$ 为特征维度，H 为特征图的高，W 为特征图宽）重塑为二维特征，便于与通道注意力特征进行融合：

$$X' = \text{Reshape}(X) \tag{7}$$

其中 $X' \in R^{C\times HW}$，接着使用卷积操作提取通道间的特征关系：

$$X_{\mathrm{c}} = \mathrm{Conv}(X) \tag{8}$$

其中 Conv 表示核为 1 的卷积操作，$X_{\mathrm{c}} \in R^{1\times H\times W}$．接下来我们将提取出的通道特征进行变形并概率化得到通道注意力特征图，具体计算过程如下：

$$X_t = \mathrm{Softmax}(\mathrm{reshape}(X_{\mathrm{c}})) \tag{9}$$

其中 $X_t \in R^{HW\times 1\times 1}$，最终将概率化通道注意力特征 X_t 与原始图像特征进行加权相乘，得到上下文特征 $X_{\mathrm{cm}} \in R^{C\times HW}$：

$$X_{\mathrm{cm}} = X_t \cdot X' \tag{10}$$

使用全局上下文特征提取模块提取特征后，本文进一步使用 Transform 注意力对特征进行提取，得到注意力增强特征．首先使用一个 k=5 个神经元的多层感知机（MLP）对上下文特征进行建模，得到 $X_{\mathrm{MLP}} \in R^{1\times 1\times C}$，具体计算过程如下：

$$X_{\mathrm{MLP}} = \mathrm{MLP}(X_{\mathrm{cm}}) \tag{11}$$

其中，MLP 代表多层感知机，最后一层使用 Sigmoid 激活函数进行激活，得到通道重要性特征 $S \in R^{1\times 1\times C}$，具体计算过程如下：

$$S = \sigma(X_{\mathrm{MLP}}) \tag{12}$$

其中σ 表示 Sigmoid 激活函数，S 的值在 0~1 之间．

最后将通道重要性特征 S 与输入特征 X 进行逐通道相乘，得到最终的输出 $X_{\mathrm{out}} \in R^{C\times H\times W}$

$$X_{\mathrm{out}} = X \cdot S \tag{13}$$

其中·表示逐元素相乘．

1.6 损失函数

本文采用加权交叉熵损失作为损失函数，加权交叉熵损失函数公式为：

$$L_{\mathrm{cross}} = -\sum_{c=1}^{M} w_c y_c \ln p_c \tag{14}$$

其中，c 和 M 分别是肿瘤类别和类别数目．w 表示类别权重，y 表示类别标签，p 表示预测概率．

2 实验结果与分析

2.1 数据集及预处理

本研究收集了两个包含正常和肿瘤脑部影像的数据集，均来自开源平台 Kaggle，分别命名为 Dataset-1 和 Dataset-2．其中，Dataset-1 数据集包含 3 762 张 MRI 影像（有肿瘤 1 683 张，无肿瘤 2 079 张），该数据集用于实验中二分类任务．Dataset-2 数据集包含 7 023 张 MRI 影像（脑膜瘤 1 621 张，胶质瘤 1 645 张，垂体瘤 1 757 张，无肿瘤 2 000 张），该数据集的图像数量较为均衡，用于实验中三分类任务的训练和评估．图 6 展示了从 Dataset-1 和 Dataset-2 数据集中抽取的正常与肿瘤脑部影像的样本，直观地展示了本研究使用的影像类型和质量．通过这种系统的实验流程和深入的数据分析，旨在提高颅内肿瘤分类的准确性，为临床诊断提供有效的辅助工具．

为了确保数据质量并提升模型的训练效果，本研究对数据进行了规范化的预处理．首先，采用数据归一化，将图像像素值调整至标准范围，以提高模型训练速度并防止数值不稳定的问题．其次，对所有图像

统一分辨率，使其满足模型输入的尺寸要求，有效避免尺寸差异带来的训练困难.

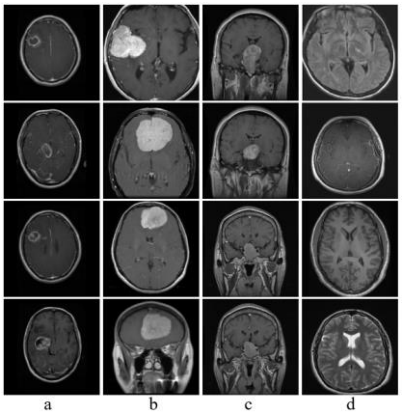


图 6　从 Dataset-1 和 Dataset-2 数据集中抽取的正常与肿瘤脑部影像的样本. a: 胶质瘤; b: 脑膜瘤; c: 垂体瘤; d: 无肿瘤

Fig. 6　Samples of normal and tumor brain images extracted from Dataset-1 and Dataset-2. a: Glioma, b: Meningioma, c: Pituitary, d: No tumor

2.2　参数设计与模型评估

训练网络模型的设备内存为 256 GB，处理器为 IntelXeon6246，GPU 为 NVIDIA RTX 4090 由 NVIDIA 公司（美国）生产，深度学习框架为 Pytorch 2.1.2，CUDA 11.8，Python 3.8．训练时采用 Adma 优化器进行优化．实验设置的迭代的批量大小为 128，训练次数为 60，所有图像均统一调整为 224×224 像素，以适配主流卷积神经网络的输入尺寸.

此外，为评估模型在实际部署中的可行性，本文在 NVIDIA RTX 4090 显卡平台上测量了 AD-Net 在推理阶段的速度，平均处理每张 MRI 图像耗时约 12.6 ms，显示出该模型具备快速响应和临床部署的潜力.

为了准确评估网络的性能，本文采用 Accuracy（准确率）、Precision（精确率）、Recall（召回率）、F1 分数、Kappa 系数以及混淆矩阵作为评价指标.

Accuracy（准确率）是指分类器对给定测试数据集中正确分类的样本数与总样本数之比：

$$\text{Accuracy}=\frac{\text{TP+TN}}{\text{TP+TN+FP+FN}} \tag{15}$$

其中，TP 表示真正例，模型正确预测为正类的样本数量；TN 表示真反例，模型正确预测为负类的样本数量；FP 表示假正例，模型将负类错误预测为正类的样本数量；FN 表示假反例，模型将正类错误预测为负类的样本数量.

Precision（精确率）是指分类器判定为正样本中，真正为正样本所占的比例：

$$\text{Precision}=\frac{\text{TP}}{\text{TP+FP}} \tag{16}$$

Recall（召回率）是指在真实正样本中，被正确判定为正样本的比例：

$$\text{Recall}=\frac{\text{TP}}{\text{TP+FN}} \tag{17}$$

F1 分数是精确率与召回率的调和平均值：

$$\text{F1}=\frac{2\times\text{Precision}\times\text{Recall}}{\text{Precision+Recall}} \tag{18}$$

Specificity（特异性）是衡量模型识别负类（非目标类）能力的指标：

$$\text{Specificity} = \frac{\text{TN}}{\text{TN+FP}} \tag{19}$$

Kappa 系数是用于一致性检验的指标，也可用于衡量分类效果：

$$\text{Kappa} = \frac{p_{\text{o}} - p_{\text{e}}}{1 - p_{\text{e}}} \tag{20}$$

$$p_{\text{e}} = \frac{\sum_{k=1}^{n}(\sum_{i=1}^{n} x_{ik} \times \sum_{j=1}^{n} x_{kj})}{(\sum_{j=1}^{n}\sum_{i=1}^{n} x_{ij})^2} \tag{21}$$

其中，p_{o} 表示实际观测到的一致率，p_{e} 表示随机一致率，n 表示类别数即混淆矩阵的维度，x_{ij} 表示混淆矩阵中的一个计数即真实类别为 i，预测类别为 j 的样本数量．Kappa 系数用于衡量两个评分之间的一致性，其中二次加权 Kappa 通过人工评分与模型预测评分的差异程度进行计算．Kappa 系数值的范围在–1 到 1 之间，–1 表示评分者之间完全不一致，1 表示评分者之间完全一致．通常，该指标通过模型实际获得的相同评分数量与基于随机概率预期获得的相同评分数量之间的差异来分析．当模型实际获得相同评分的数量与随机概率预期获得的相同评分数量几乎一致时，Kappa 系数值便接近于 1，表明两个评分之间具有高度的一致性．

2.3 实验设计

图 7 展示了本文所提出的基于 AD-Net 的颅内肿瘤 MRI 图像分类框架，整体分为两个部分：(a)部分为整体分类流程概览，(b)部分为模型训练与测试阶段．在(a)部分中，系统首先以颅内肿瘤 MRI 图像作为输入，经过数据预处理（Data Preprocessing）．预处理后的图像被送入颅内肿瘤分类模块（Brain Tumor Classification Scheme），该模块可将图像分为四类：胶质瘤（Glioma）、脑膜瘤（Meningioma）、垂体瘤（Pituitary）以及无肿瘤（No tumor）．这一步为整个系统提供了基础的分类目标．在(b)部分中，流程展示了 AD-Net 模型的训练和推理细节．首先，对原始数据集进行划分，其中 80%的数据作为训练集，20%作为测试集．训练集被输入到 AD-Net 模型中，AD-Net 集成了动态卷积模块（Dynamic Convolution）和通道注意力模块（Channel Attention），前者增强了模型对局部特征的自适应建模能力，后者则使模型更关注对分类有贡献的通道特征．在训练阶段，模型还利用验证集对网络性能进行实时监控与优化，通过最小化验证损失（Validation Loss）进行模型调整，提升网络的泛化能力．训练好的 AD-Net 模型被用于对测试集中的未见明显颅内肿瘤的图像进行分类．在测试阶段，图像同样经过动态卷积与通道注意力模块处理，以实现对图像类别的准确预测．最终，模型输出的结果将通过多种评估指标进行性能分析，包括特异性（Specificity）、F1 分数（F1-Score）、精确率（Precision）、召回率（Recall）、准确率（Accuracy）以及 Kappa 系数．这些评价指标从不同维度反映了模型的分类效果、鲁棒性和泛化能力．

2.4 结果与分析

在本研究中，我们提出了一个新的深度学习框架 AD-Net，用于颅内肿瘤的识别和分类．通过五折交叉验证方法对数据集进行划分，确保了训练和测试的数据独立性和代表性．

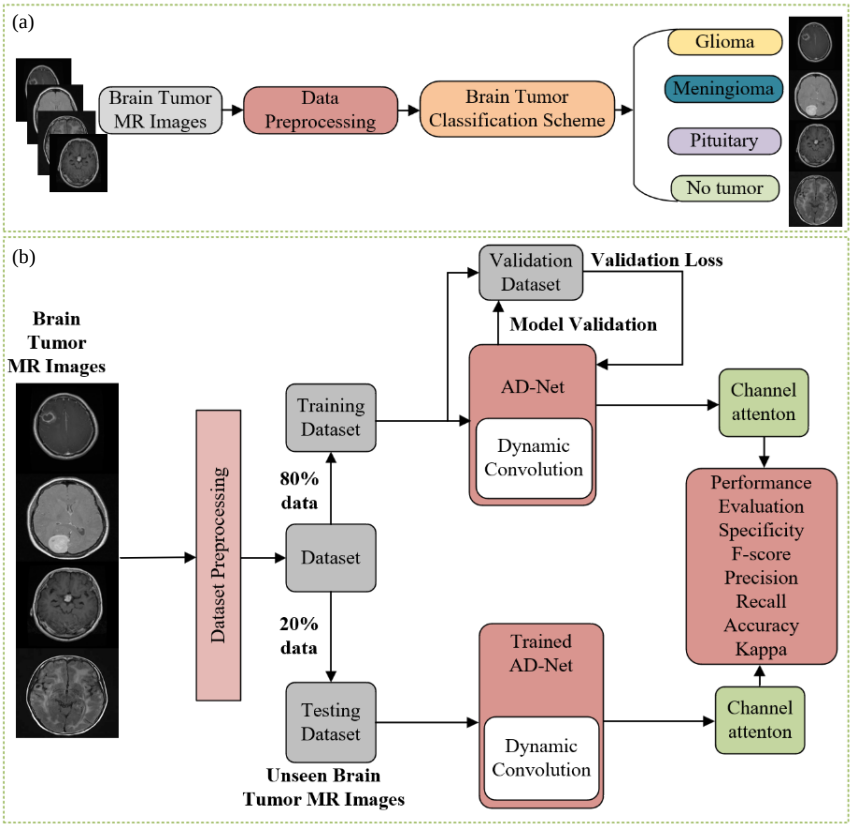


图 7　本文所提出的基于 AD-Net 的颅内肿瘤 MRI 图像分类框架. (a)实验简易流程; (b)实验详细流程

Fig. 7　The AD-Net-based framework for intracranial tumor MRI image classification proposed in this paper. (a) Simplified experimental procedure, (b) Detailed experimental procedure

图 8 展示了 AD-Net 模型在多个训练周期（Epoch）中的几个关键性能指标：训练准确率（Training Accuracy）、验证准确率（Validation Accuracy）、训练 Kappa 系数值（Training Kappa）、验证 Kappa 系数值（Validation Kappa）和损失（Loss）变化情况．每个子图从左至右分别代表了训练和验证过程中这些指标的变化，反映了模型在学习过程中的行为和性能调整．模型的训练损失逐渐下降，并在一定的训练周期后趋于稳定，这表明模型逐步从训练数据中学习到了有价值的特征．此外，训练和验证的精度以及 Kappa 系数值也随着周期的增加而提高，反映了模型在识别颅内肿瘤图像方面的准确性逐渐增强．特别是在后期周期，验证精度和 Kappa 系数值达到了最高，说明模型具有良好的泛化能力．我们还注意到，在某些周期后，尽管训练精度持续提高，但验证精度和 Kappa 系数值却出现了波动或下降，这可能是模型开始出现过拟合的迹象．为此，我们引入了提前停止的策略，即如果验证损失在连续多个周期内没有显著下降，则停止训练．这有助于保持模型的泛化能力，避免无谓的计算资源浪费．

在实验的最后，我们在测试集上对模型进行了最终评估．如图 9 所示的混淆矩阵清晰地展示了模型对于胶质瘤、脑膜瘤、垂体瘤以及无肿瘤四个类别的分类结果．从混淆矩阵中可以观察到，模型在区分各类颅内肿瘤时表现出很高的准确性，整体分类准确率达到了 0.974 7．此外，计算得到的二次加权 Kappa 系数值为 0.977 3，进一步验证了模型预测结果的高度一致性与稳定性，说明 AD-Net 模型在颅内肿瘤图像分类任务中表现出了优越性和鲁棒性．

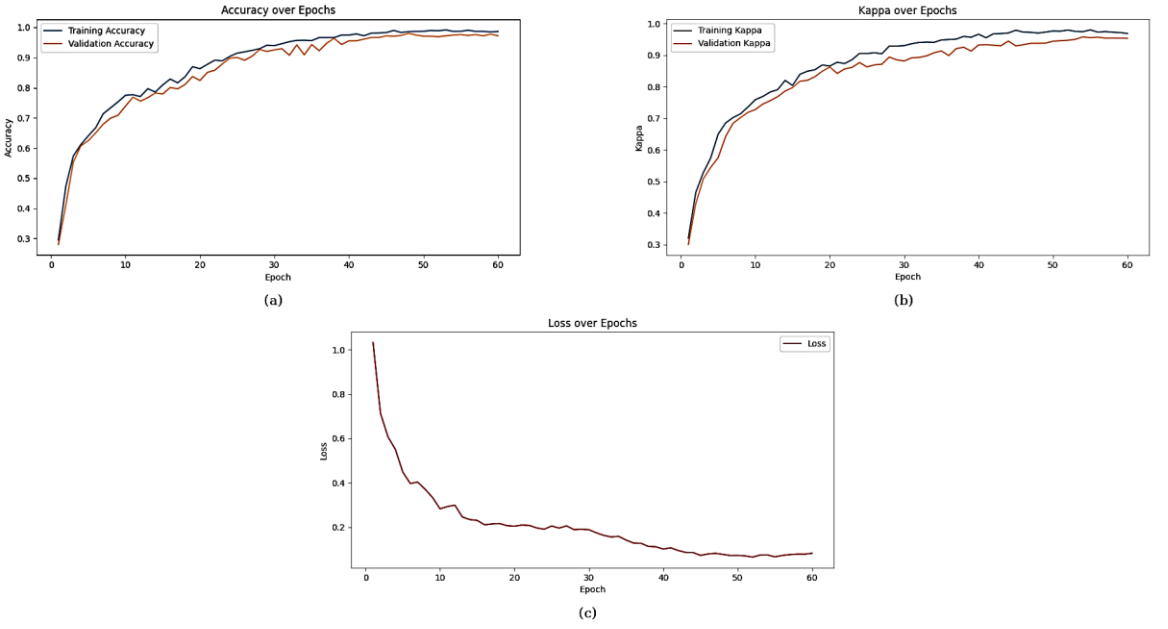


图 8 AD-Net 模型在 60 个训练周期（Epoch）中的几个关键性能指标(a)训练准确率与验证准确率、(b)训练 Kappa 系数与验证 Kappa 系数及(c)损失函数曲线图

Fig. 8 of the AD-Net model over 60 training epochs: (a) training and validation accuracy, (b) training and validation Kappa values, and (c) loss function curves

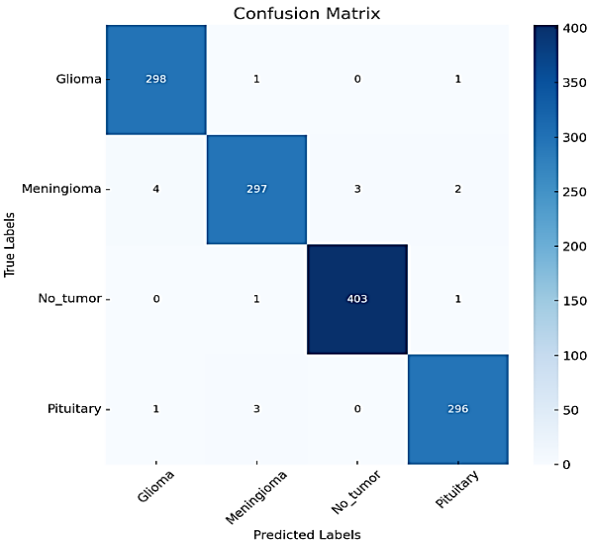


图 9 混淆矩阵

Fig. 9 Confusion Matrix

2.5 对比实验

在本研究中，AD-Net 模型的主要优势包括：（1）轻量级架构，通过将二分类与三分类的策略相结合，显著缩短了模型训练时间，同时使用非线性操作增加了网络的多样性及分类效果；（2）在训练过程中能够优化每层的学习权重，提高学习效率；（3）与传统的 CNN 模型相比，在显著降低计算复杂性的同时，实

现了更优越的分类性能．为了直观展示这些优势，我们在图 10 中绘制了 AD-Net、ResNet101[29,30]、Self-ONN 系列[31,32]、Vanilla CNN 系列[33-35]和 DenseNet201[36]等模型在训练过程中的准确率变化曲线．

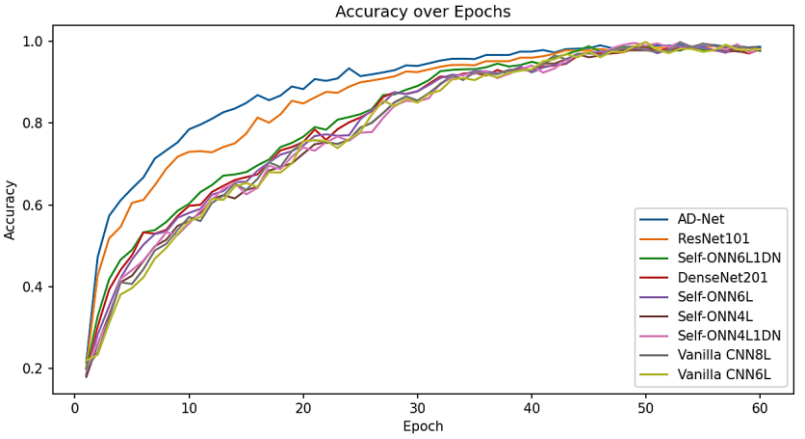


图 10　对比实验准确率曲线图

Fig. 10　Accuracy curves for comparative experiments

所有模型均使用相同的原始 MRI 颅内肿瘤图像数据集进行训练，以确保评估的公平性．这些模型旨在对四个类别进行分类：胶质瘤、垂体瘤、脑膜瘤以及无肿瘤．从图 10 可以明显看出，AD-Net 模型的学习曲线在训练初期迅速上升，并在整个训练周期内保持高准确率，显示出其快速收敛和高泛化能力．

对比的分类性能结果显示在表 1 中．结果表明，尽管传统的深层 CNN 模型如 DenseNet201 和 ResNet101 在准确率上表现优秀，但 AD-Net 在所有对比模型中表现最为突出，达到了最高的分类性能．具体来说，AD-Net 在原始 MRI 颅内肿瘤图像上展现了 0.974 7 的准确率、0.969 3 的精确率、0.968 5 的召回率、0.979 5 的特异性和 0.968 3 的 F1 分数．

表 1　对比实验结果

Table 1　Comparative experimental results

模型名称	准确率(Accuracy)	精确率(Precision)	召回率(Recall)	特异性(Specifity)	F1 分数(F1 Score)
Self-ONN4L1DN	0.9390±0.0129	0.9348±0.0133	0.9377±0.013	0.9434±0.0125	0.9350±0.0133
Self-ONN4L	0.9376±0.0130	0.9356±0.0132	0.9376±0.0130	0.9428±0.0125	0.9375±0.0131
Self-ONN6L	0.9419±0.0126	0.9485±0.0119	0.9429±0.0125	0.9547±0.0112	0.9458±0.0122
Self-ONN6L1DN	0.9650±0.0112	0.9553±0.0111	0.9520±0.0115	0.9611±0.0104	0.9531±0.0114
Vanilla CNN8L	0.9295±0.0138	0.9289±0.0139	0.9292±0.0138	0.9395±0.0129	0.9278±0.0140
Vanilla CNN6L	0.9283±0.0139	0.9276±0.0140	0.9290±0.0139	0.9387±0.0129	0.9245±0.0143
DenseNet201	0.9458±0.0122	0.9455±0.0122	0.9428±0.0125	0.9584±0.0108	0.9480±0.0120
ResNet101	0.9490±0.0107	0.9596±0.0106	0.9589±0.0107	0.9589±0.0107	0.9586±0.0107
AD-Net	**0.9747**±0.0092	**0.9693**±0.0093	**0.9685**±0.0094	**0.9795**±0.0076	**0.9683**±0.0095

此外，为了定量评估模型性能，我们还考虑了测试数据的平均值和标准偏差．测试数据集被均匀分为五折，以测试模型的稳定性和可靠性．AD-Net 模型在这些评估中显示出较低的标准偏差值，表明其性能在不同测试集上的变异性较小，从而证明了其优越的稳定性和可靠性．这一点从表 1 的统计数据可以得到进一步的证实．

因此，可以得出结论，AD-Net 在将 MRI 颅内肿瘤图像分类为四个类别方面表现优于其他对比模型，证实了其作为颅内肿瘤诊断工具的实用性和有效性．未来的工作将进一步探索该模型在更广泛医学影像任

务中的潜力及应用.

2.6 消融实验

为验证本文所提 AD-Net 模型的有效性，我们将其与其他几种模型进行了对比，包括 ResNet50[23]、ResNet50 加入通道注意力模块[26]（Channel Attention）和动态卷积[28]（Dynamic Convolution）的改进版本. 这种比较旨在展示 AD-Net 在不同组件增强下的性能变化，以及这些改进如何促进模型在颅内肿瘤分类任务中的表现. 表 2 中的消融实验结果显示了各模型的分类性能，包括准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数（F1 Score）和 Kappa 系数. 从表中数据可以看出，原始的 ResNet50 模型准确率为 0.936 2，加入通道注意力的 ResNet50 模型准确率提高到 0.951 9，显示通道注意力机制的有效性；而加入动态卷积后，模型准确率提升至 0.960 1，表明动态卷积在特征提取方面的有效性. AD-Net 模型在全部评价指标上表现最优，准确率达到 0.974 7，显著优于其他对比模型。该模型以 ResNet50 为基础，融合了动态卷积与通道注意力机制，能够自适应调整特征提取过程中的权重分布，更有效地捕捉颅内肿瘤 MRI 图像中的关键信息. 其高性能得益于模型能够同时关注全局和局部特征，以及通过高效的多尺度特征融合策略提高分类的准确性. 这不仅有助于模型识别不同类型肿瘤间的宏观差异，还能够细致地捕捉肿瘤间的细微差别，从而提升了颅内肿瘤分类的整体性能.

表 2 消融实验结果

Table 2 Ablation study results

模型名称	准确率(Accracy)	精确率(Precision)	召回率(Recall)	F1 分数(F1 Score)	Kappa
ResNet50	0.9362	0.9251	0.9331	0.9434	0.9325
ResNet50+Channel Attention	0.9519	0.9369	0.9550	0.9552	0.9484
ResNet50+Dynamic Convolution	0.9601	0.9553	0.9433	0.9565	0.9526
AD-Net	**0.9747**	**0.9693**	**0.9685**	**0.9683**	**0.9773**

3 结论与展望

本文针对颅内肿瘤 MRI 图像分类任务，提出了一种高效、轻量化的深度学习模型——AD-Net. 该模型通过融合动态卷积模块和通道注意力机制，在提升特征表达能力的同时，有效地降低了模型复杂度和计算资源消耗. 实验表明，AD-Net 在多个开源 MRI 脑部影像数据集上，尤其是在复杂的多类别分类任务中，均取得了优异的分类效果. 模型在准确率、精确率、召回率、F1 分数和 Kappa 系数等评价指标上全面优于传统深度学习方法，显示出良好的泛化性能和实际应用潜力. 进一步地，AD-Net 在推理速度上表现突出，能够满足临床实际部署对实时性的要求，尤其适合资源受限的医疗场景.

尽管取得了显著成果，本文研究仍存在一定的局限性. 首先，对于假阳性和假阴性结果尚未展开深入系统的分析. 在实际临床中，假阳性可能导致无肿瘤患者承担不必要的诊疗风险和经济负担，而假阴性会遗漏真实患者，延误治疗，带来严重后果. 本研究在分析模型预测结果时，发现极少数正常样本被误判为肿瘤（如脑膜瘤），提示模型在处理边界模糊或影像质量较差的样本时仍有改进空间. 其次，目前的模型训练与测试主要依赖于开源数据集，不可避免地存在与真实复杂临床环境之间的分布差异. 数据集样本量、采集设备、成像协议等因素的差异，都可能影响模型在实际中的泛化能力和鲁棒性.

鉴于以上不足，未来的研究可从以下几个方面予以拓展：

（1）加强假阳性与假阴性机制分析：引入更为细致的错误分析工具，对模型误判样本进行深入溯源，结合放射科专家的人工标注，共建高质量的标注数据集，提高模型对边界复杂和异质性样本的判别能力. 进

一步，还可设计专门损失函数或采用样本重加权策略，缓解类别不平衡对预测结果的影响．

（2）提升模型可解释性和临床信任度：在现有 Attention 可视化基础上，构建统一的可解释性框架，将模型的显著特征区域和诊断依据以可视化方式呈现，辅助医生理解模型诊断逻辑．并通过与医生诊断结果的系统性对比，评估模型的辅助诊断价值和实际应用局限．

（3）跨数据集、跨机构泛化验证：未来可收集更大规模、跨平台、跨中心的多源医学影像数据集，涵盖不同人群、成像设备与协议．通过域自适应、迁移学习等方法提升模型的鲁棒性与普适性，缩小模型性能在不同实际场景间的差异．

（4）推动多模态与多任务深度学习研究：进一步将 MRI 与 CT、PET、临床电子病历等多模态信息结合，探索端到端的多模态特征融合网络．同时，根据实际临床需求，将肿瘤的分级、分区、预后与随访等多任务联合建模，完善智能影像辅助诊断生态．

（5）引入隐私保护和协作学习机制：在法律法规与伦理框架下，引入联邦学习等分布式机器学习技术，实现多医疗中心间隐私安全的数据协作训练，提升模型训练数据多样性，保障数据主权．

综上所述，AD-Net 为颅内肿瘤 MRI 图像的智能分类提供了高效实用的技术方案，对智能医疗影像诊断具有重要的理论和应用意义．未来，随着多维数据融合、模型可解释性增强以及安全协同学习机制等技术的不断成熟，基于深度学习的医学影像智能诊断有望在临床精准医疗中发挥更大作用．

利益冲突

无

参考文献：

[1] AFSHAR P, MOHAMMADI A, PLATANIOTIS K N. Bayescap: A bayesian approach to brain tumor classification using capsule networks[J]. IEEE Signal Process Lett, 2020, 27: 2024-2028.

[2] XUE P Y, GENG C, LI Y X, et al. A classification method for cerebral aneurysms in TOF-MRA based on improved 3D ResNet50 model[J]. Chinese J Magn Reson, 2025, 42(1): 56-66.
薛培阳, 耿辰, 李郁欣, 等. 基于 3D ResNet50 改进模型的 TOF-MRA 脑动脉瘤分类方法[J]. 波谱学杂志, 2025, 42(1): 56-66.

[3] PAUL J S, PLASSARD A J, LANDMAN B A, et al. Deep learning for brain tumor classification[C]// Medical Imaging 2017: Biomedical Applications in Molecular, Structural, and Functional Imaging. Orlando, United States: SPIE, 2017, 10137: 253-268.

[4] IQBAL S, KHAN T M, NAQVI S S, et al. Ldmres-Net: a lightweight neural network for efficient medical image segmentation on iot and edge devices[J]. IEEE J Biomed Health Inform, 2023, 27(4): 1234–1242.

[5] DAI J L, HE C, WU J, et al. A segmentation network for pancreatic cystic tumors integrating dual decoder and global attention upsampling module[J]. Chinese J Magn Reson, 2024, 41(2): 151-161.
戴俊龙, 何聪, 武杰, 等. 融合双解码和全局注意力上采样模块的胰腺囊性肿瘤分割网络[J]. 波谱学杂志, 2024, 41(2): 151-161.

[6] CHANG B, SUN H Y, GAO Q Y, et al. Research progress on segmentation of multi-modal cardiac medical images using traditional methods and deep learning[J]. Chinese J Magn Reson, 2024, 41(2): 224-244.
常博, 孙灏芸, 高清宇, 等. 传统方法和深度学习用于不同模态心脏医学图像的分割研究进展[J]. 波谱学杂志, 2024, 41(2): 224-244.

[7] AFSHAR P, PLATANIOTIS K N, MOHAMMADI A. Capsule networks for brain tumor classification based on MRI images and coarse tumor boundaries[C]// ICASSP 2019-2019 IEEE international conference on acoustics, speech and signal processing (ICASSP). Athens, Greece: IEEE, 2019: 1368-1372.

[8] FENG L, WU K, PEI Z, et al. MLU-Net: A multi-level lightweight U-Net for medical image segmentation integrating frequency representation and MLP-based methods[J]. IEEE Access, 2024, 12: 20734-20751.

[9] XU Z S, YUAN X H, HUANG Z H, et al. Multi-source feature classification model for pancreatic mucinous and serous cystic neoplasms based on deep learning[J]. Chinese J Magn Reson, 2024, 41(1): 19-29.
徐真顺, 袁小涵, 黄子珩, 等. 基于深度学习的胰腺黏液性和浆液性囊性肿瘤的多源特征分类模型[J]. 波谱学杂志, 2024, 41(1): 19-29.

[10] SWATI Z N K, ZHAO Q, KABIR M, et al. Brain tumor classification for MR images using transfer learning and fine-tuning[J]. Comput Med Imaging Graph, 2019, 75: 34-46.
[11] GHASSEMI N, SHOEIBI A, ROUHANI M. Deep neural network with generative adversarial networks pre-training for brain tumor classification based on MR images[J]. Biomed Signal Process Control, 2020, 57: 101678.
[12] AFSHAR P, PLATANIOTIS K N, MOHAMMADI A. BoostCaps: a boosted capsule network for brain tumor classification[C]// 2020 42nd annual international conference of the IEEE engineering in medicine & biology society (EMBC). Montreal, QC, Canada: IEEE, 2020: 1075-1079.
[13] BODAPATI J D, SHAIK N S, NARALASETTI V, et al. Joint training of two-channel deep neural network for brain tumor classification[J]. Signal Image Video P, 2021, 15(4): 753-760.
[14] KALKHOF J, GONZÁLEZ C, MUKHOPADHYAY A. Med-nca: Robust and lightweight segmentation with neural cellular automata[C]// International Conference on Information Processing in Medical Imaging. San Antonio, Texas, USA. Cham: Springer Nature Switzerland, 2023: 705-716.
[15] ABIRAMI S, VENKATESAN G K D P. Deep learning and spark architecture based intelligent brain tumor MRI image severity classification[J]. Biomed Signal Process Control, 2022, 76: 103644.
[16] WOO S, PARK J, LEE J Y, et al. Cbam: Convolutional block attention module[C]// Proceedings of the European conference on computer vision (ECCV). Munich, Germany. Cham: Springer, 2018: 3-19.
[17] HAN B, XU J, WANG Y J, et al. Triple classification of BI-RADS 3-5 breast lesions based on MRI radiomics[J]. Chinese J Magn Reson, 2023, 40(1): 52-67.
韩冰, 徐晶, 王远军, 等. 基于 MRI 影像组学的 BI-RADS 3-5 类乳腺病变三分类[J]. 波谱学杂志, 2023, 40(1): 52-67.
[18] ZHANG H, GOODFELLOW I, METAXAS D, et al. Self-attention generative adversarial networks[C]// International conference on machine learning. Long Beach, CA, USA. PMLR, 2019: 7354-7363.
[19] CAO Y, XU J, LIN S, et al. Gcnet: Non-local networks meet squeeze-excitation networks and beyond[C]// Proceedings of the IEEE/CVF international conference on computer vision workshops. Seoul, South Korea: IEEE, 2019: 1971-1980.
[20] SHARMA P, NAYAK D R, BALABANTARAY B K, et al. A survey on cancer detection via convolutional neural networks: Current challenges and future directions[J]. Neural Netw, 2024, 169: 637-659.
[21] BODAPATI J D, SHAREEF S N, NARALASETTI V, et al. Msenet: Multi-modal squeeze-and-excitation network for brain tumor severity prediction[J]. Int J Pattern Recognit Artif Intell, 2021, 35(7): 2157005.
[22] DUTTA T K, NAYAK D R. CDANet: Channel split dual attention based CNN for brain tumor classification in MR images[C]// 2022 IEEE international conference on image processing (ICIP). Bordeaux, France: IEEE, 2022: 4208-4212.
[23] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. Las Vegas, NV, USA: IEEE, 2016: 770-778.
[24] HASSANI A, WALTON S, SHAH N, et al. Escaping the big data paradigm with compact transformers[J]. arXiv: 2104.05704, 2021.
[25] LI K, WANG Y, ZHANG J, et al. Uniformer: Unifying convolution and self-attention for visual recognition[J]. IEEE Trans Pattern Anal Mach Intell, 2023, 45(10): 12581-12600.
[26] ALANAZI M F, ALI M U, HUSSAIN S J, et al. Brain tumor/mass classification framework using magnetic-resonance-imaging-based isolated and developed transfer deep-learning model[J]. Sensors, 2022, 22(1): 372.
[27] ZAHOOR M M, QURESHI S A, BIBI S, et al. A new deep hybrid boosted and ensemble learning-based brain tumor analysis using MRI[J]. Sensors, 2022, 22(7): 2726.
[28] CHEN Y, DAI X, LIU M, et al. Dynamic convolution: Attention over convolution kernels[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. Seattle, Washington, USA: IEEE, 2020: 11030-11039.
[29] CAO R, YANG F, MA S C, et al. Development and interpretation of a pathomics-based model for the prediction of microsatellite instability in Colorectal Cancer[J]. Theranostics, 2020, 10(24): 11080.
[30] NAWAZ K, ZANIB A, SHABIR I, et al. Skin cancer detection using dermoscopic images with convolutional neural network[J]. Sci Rep, 2025, 15(1): 7252.
[31] MAMUN O R, RASHID M D, NASHBAT M, ASHRAF A, et al. Self-DSNet: A novel self-ONNs based deep learning framework for multimodal driving distraction detection[J]. IEEE Access, 2025, 13: 42322-42335.
[32] YIN S, LI H, TENG L, et al. Brain CT image classification based on mask RCNN and attention mechanism[J]. Sci Rep, 2024, 14(1): 29300.
[33] ZENG L, ZHANG H H. Robust brain MRI image classification with SIBOW-SVM[J]. Comput Med Imaging Graph, 2024, 118: 102451.
[34] HUA C, CHEN Y, TAO J, et al. Dual-pathway EEG model with channel attention for virtual reality motion sickness detection[J]. J Neurosci Methods, 2025, 418: 110425.
[35] DUAN X, CHEN Y, DUAN X, et al. Improved grain boundary reconstruction method based on channel attention mechanism[J]. Materials, 2025, 18(2): 253.
[36] AL-KHULAIDI N, ALMOURISH M H, TALEB E M A, et al. Improving detection and classification of brain tumors using DenseNet201[J]. J Sci Technol, 2025, 30(6): 2855.